Leistungsbeurteilung 259 V2

Modulnummer	259	Verordnung	2021	Anbieter Version	1.0
Titel	ICT-Lösungen mit Machine Learning entwickeln				
Autor	Christian Witschard christian.witschard@bbbaden.ch				

		Datum:	
Name:		Vorname:	
Klasse:		Experte:	
Note:			

Hilfsmittel	Folgende Hilfsmittel sind erlaubt: Alle Unterlagen
Prüfungsdauer	8 Lektionen zu 45 min während des gesamten Moduls
Prüfungsinfrastruktur	Folgende Infrastruktur steht zur Verfügung: Eigenes Notebook
Notenskala	Linear (Note = 1 + 5 * $\frac{Erreichte\ Punktzahl}{Gesamte\ Punktzahl}$), auf halbe Noten gerundet. 1 ist die schlechteste, 6 die beste Note.
Objekt	Bestehende Machine Learning Plattform mit einer einfachen ICT-Lösung zur Analyse eines Datenbestandes (Klassifizierung, Clustering oder Prediction).

HZ	Handlungsziel	Aufgabe(n)
1	Identifiziert und bewertet technische Varianten aus dem Machine Learning Umfeld für die Lösung eines Problems.	3.2
2	Setzt die Anforderungen des Datenschutzes bei der Sammlung und Nutzung von Daten um.	1.2
3	Bereitet Rohdaten für die maschinelle Verarbeitung auf, ordnet und analysiert diese im Hinblick auf die Verwendung im Machine Learning Umfeld.	2.4
4	Klärt die sequenzielle Abhängigkeit von Aktivitäten der gewählten Machine Learning Technologie und definiert die zeitliche Reihenfolge.	1-4
5	Evaluiert ein performantes und passendes Modell aus dem Machine Learning Umfeld für die Entwicklung einer ICT-Lösung.	4.4
6	Nimmt Dienste und ICT-Lösungen zum Einsatz von Machine Learning Technologien in Betrieb.	3
7	Entwickelt nach Vorgaben eine ICT-Lösung mit der geeigneten Machine Learning Technologie.	1-4

Bewertung:

Aufgabe	Gewichtung	Punkte	Bewertung
	1	3	Die administrativen Vorgaben sind eingehalten
1.1	1	3	Die Datensätze sind gemäss Anforderungen ausgewählt und eignen sich für ML.
1.2	1	3	Der Datenschutz wurde berücksichtigt.
2.1	1	3	Es wurde ein für die Analyse zielführendes Feld ausgewählt.
2.2	2	3	Die Berechnungen sind korrekt durchgeführt worden.
2.3	1	3	Die Grafik ist korrekt erstellt und sinnvoll ausgesucht worden.
2.4	1	3	Die Daten wurden korrekt skaliert, dort, wo es nötig und sinnvoll ist. *oder* Die Argumentation, warum keine Skalierung nötig ist, wurde stimmig aufgestellt.
3.1	1	3	Die Aufteilung wurde korrekt vorgenommen.
3.2	2	3	Es wurde ein passender Algorithmus gewählt, und das Modell korrekt berechnet.
3.3	1	3	Die Überprüfung wurde korrekt und ausführlich durchgeführt.
4.1	1	3	Es wurden die wichtigen, aussagekräftigen Felder richtig erkannt.
4.2	2	3	Es wurde eine passende Messmetrik gewählt und diese korrekt berechnet.
4.3	1	3	Es sind geeignete Berechnungen erstellt worden.
4.4	1	3	Die Erklärungen wurden sinnvoll aufgestellt.

Hinweise:

- Diese Prüfung ist eine Einzelarbeit.
- Es dürfen keine alten Prüfungen und/oder Daten von alten Prüfungen verwendet werden.
- Betrügereien, wie Spicken o.Ä., oder Betrugsversuche führen zum Ausschluss aus der Prüfung.
- Im Falle eines Betrugs gilt die Leistungsbeurteilung als absolviert, aber nicht bestanden.
- Geben Sie diese Aufgabenstellung und den Lösungsbogen mit Nachname, Vorname und Klasse beschriftet ab.
- Bezeichnen Sie Lösungen und Korrekturen klar und deutlich.
- Verwenden Sie einen dokumentenechten Stift (Tinte/Kugelschreiber).
- Wenn Sie Lösungen elektronisch oder auf Zusatzblättern abgeben, verweisen Sie auf diese Zusatzmaterialien auf Ihrem Aufgabenblatt.
- Alle Dateien müssen in einem Ordner abgelegt werden, dessen Name dem Format NameVornameLB-259 entspricht. (z.B. MuellerHansLB-259).
    - Die gepackte Datei muss gleich wie der Ordner benannt werden.
    - Programmierprojekte müssen gleich wie der Ordner benannt werden.
- Folgende Formate sind bei den elektronischen Lösungen erlaubt:
    - Programmcode: Visual Studio-Projekte oder Dateien mit Ordnerhierarchie
    - Bilder: jpg, gif, png
    - Texte: ASCII-Texte, Microsoft Word, Adobe Acrobat pdf
    - Anderes: Microsoft Excel, Microsoft PowerPoint
- Die elektronischen Lösungen werden am Schluss der Prüfung auf Moodle hochgeladen.
- Elektronisch abgegebene Lösungen werden mit Vorteil gezippt.
- Sie sind verantwortlich dafür, dass Sie alle Dateien abgeben.
- Alle Daten dieser LB (Aufgabendateien und Lösungen) müssen sofort nach dem Abschluss der LB und dem Hochladen gelöscht werden.
- Vor Beginn der Prüfung abgegebene Daten:
    - Keine oder Auflistung der Dateien
- Regelung zu verspätet eingereichter Leistungsbeurteilungen:
    - Pro angefangene 24h Verspätung wird eine halbe Note (0.5 Notenpunkte) abgezogen. Verspätet eingereichte Leistungsbeurteilungen werden korrigiert, bewertet und dann mit dem Abzug der Verspätung verrechnet.
    - Aufschiebende Wirkungen haben nicht planbare Absenzen wie Krankheit oder Unfall, sofern Sie vom Berufslernenden bei Eintritt des Ereignisses kommuniziert wurden. Die Lehrperson entscheidet über die Abgabetermine.
    - Dies gilt auch für verspätete Abgaben von Teilaufgaben.

I Administrative Vorgaben

1. Halten Sie alle administrativen Vorgaben (unter anderem diejenigen auf Seite 3) ein. (1. Pkt.)

II Fallbeschreibung

Es begleitet dieses Modul eine Projektarbeit, für welche Sie während des Unterrichts acht Lektionen Zeit bekommen, um daran zu arbeiten. Ziel ist es, dass Sie von Anfang bis Schluss eine einfache Lösung maschinellen Lernens implementieren; d.h. mittels eines Datensatzes ein Modell berechnen, mit welchem Sie Vorhersagen machen können, und dieses evaluieren. Sie sind dabei frei in der Wahl Ihres Datensatzes, Ihres Modells und Ihrer Frage; und werden sogar ermutigt, sich einen Themenbereich auszuwählen, der in Ihrem Interessensfeld liegt.

Sie müssen die Teilaufträge nach Angaben der Lehrperson abgeben.

III Aufträge

Teilauftrag 0: Vorarbeit

Erstellen Sie ein neues Repository auf https://gitlab.bbbaden.ch/ und geben Sie ihm einen Namen, der zu Ihrem Projekt passt. Sie werden die einzelnen Abgaben, die im Zuge dieses Projekts entstehen, dort hochladen und die Adresse Ihres *repository* jeweils abgeben.

Stellen Sie sicher, dass Sie der Lehrperson die Berechtigung «Maintainer» oder «Developer» auf Ihrem Repository zuweisen. Alternativ können Sie auch die Sichtbarkeit des *repository* auf Public setzen. Die Lehrperson muss Ihre Arbeit bewerten können.

Teilauftrag 1: Datenbeschaffung

Finden Sie sich einen geeigneten Datensatz, auf welchem Sie Ihr Projekt aufbauen. Beachten Sie dabei Folgendes:

- Er muss ausreichend gross sein, d.h. mindestens 10 000 Zeilen, Einträge o.ä. haben. Dies ist ein sehr grober Richtwert, welcher sich je nach Art des Datensatzes verändern kann; wichtig ist, dass Sie genug Daten haben, um aussagekräftige Modelle berechnen zu können.
- Er muss verschiedene Felder verfügen, welche auch im Alltag in einem Bezug zueinander stehen, d.h. gewisse Felder sollten in Abhängigkeit von anderen Feldern stehen, die aber nicht offensichtlich ist.
- Er muss frei zugänglich sein, d.h. unter einer CC-, MIT- oder vergleichbaren Lizenz veröffentlicht worden sein.
- Vorhersagen lassen sich besser mit numerischen Feldern berechnen.

Führen Sie folgende Arbeiten durch:

1. Laden Sie diesen Datensatz herunter, bereinigen Sie ihn (eventuell in Excel) und laden Sie ihn auf Ihr *repository* hoch. Falls der Datensatz zu gross ist, dann nehmen Sie die ersten 1000 Zeilen, Einträge o.ä. und laden Sie diese als Demonstration hoch.
2. Verfassen Sie ein README.txt, in welcher Sie in 50 bis 100 Wörtern Ihren Datensatz und seine Felder beschreiben. Beschreiben Sie in *weiteren* 50 bis 100 Wörtern, inwiefern der Datensatz Datenschutz-Richtlinien tangiert oder nicht, und welche Massnahmen entweder von den Erstellern des Datensatzes oder von Ihnen getroffen wurden, um den Datenschutz zu gewährleisten. Fügen Sie dieses README.txt ebenfalls Ihrem *repository* hinzu.
3. Senden Sie die Adresse Ihres *repository* an Ihre Lehrperson. Sie finden hierzu auf Moodle ein Formular, über welches Sie die Abgabe tätigen können

💡 Sie finden eine gute Auswahl an Datensätzen beispielsweise auf kaggle.com und 🤗 huggingface.co.

Teilauftrag 2: Datenbeschreibung

Machen Sie sich mit Ihren Daten vertraut und bereiten Sie sie auf die programmatische Verarbeitung vor. Wie dies konkret aussieht, hängt von Ihrem Projekt ab, aber in jedem Fall sollten Sie Ihren Code, Ihre Berechnungen und Ihre Erkenntnisse in einem Notizbuch namens Data_description.ipynb zusammenfassen, welches Sie Ihrem *repository* hinzufügen.

Aufgaben:

1. Für welches Daten-Feld möchten Sie Vorhersagen treffen können?
2. Bestimmen Sie für jedes Feld einige relevante statistische Informationen wie beispielsweise Median und Standardabweichung.
3. Erstellen Sie mindestens eine Grafik, beispielsweise ein Histogramm für eines der Datenfelder oder ein Streudiagramm für mehrere Felder.
4. Skalieren Sie mindestens ein Datenfeld; oder argumentieren Sie in weiteren 50 bis 100 Wörtern in Ihrem Notizbuch, warum dies bei Ihrem Datensatz nicht sinnvoll ist.
5. Falls sich die Adresse Ihres *repository* geändert haben sollte, so senden Sie es via Formular an Ihre Lehrperson.

Teilauftrag 3: Model

Erstellen Sie ein neues Notizbuch namens Model.ipynb, in welchem Sie mindestens ein Modell berechnen und dieses benutzen, um eine Vorhersage zu treffen.

Aufgaben:

1. Teilen Sie Ihren Datensatz in einen *test*- und einen *train*-Satz ein.
2. Bestimmen Sie einen Algorithmus aus sklearn, der für Ihren Datensatz und Ihr Problem geeignet ist. Erklären Sie Ihre Entscheidung in 50 bis 100 Wörtern. Alternativ dazu können Sie auch verschiedene Algorithmen evaluieren und so bestimmen, welcher am besten geeignet ist. Berechnen Sie ein Modell mittels Ihres ausgesuchten Algorithmus auf Ihren *train*-Daten.
3. Testen Sie, wie gut Ihr Modell funktioniert, indem Sie einige Vorhersagen aus dem *test*-Datensatz generieren und diese manuell auf ihre Sinnhaftigkeit überprüfen. Fassen Sie Ihre Erkenntnisse in 50 bis 100 Wörtern zusammen.
4. Fügen Sie die Dokumentation Ihrem *repository* hinzu.
5. Falls sich die Adresse Ihres *repository* geändert haben sollte, so senden Sie es via Formular an Ihre Lehrperson.

Teilauftrag 4: Evaluation

Erstellen Sie ein Notizbuch namens Evaluation.ipynb.

Aufgaben:

1. Bestimmen Sie, welche Felder Ihrer Daten für Ihr Modell besonders aussagekräftig sind.
2. Wählen Sie eine geeignete Messmetrik für Ihr Modell und berechnen Sie sie.
3. Wählen Sie geeignete Bedingungen und erstellen Sie eine Wahrheitsmatrix (*confusion matrix* wie im Auftrag 1670 erklärt) für Ihr Modell. Berechnen Sie darüber hinaus Sensitivität und Spezifizität.
4. Fassen Sie in 50 bis 100 Wörtern zusammen, wie gut Ihr Modell funktioniert, und stellen Sie Hypothesen auf, warum.
5. Fügen Sie die Dokumentation Ihrem *repository* hinzu.
6. Falls sich die Adresse Ihres *repository* geändert haben sollte, so senden Sie es via Formular an Ihre Lehrperson.

```
Selbstständigkeitserklärung

Hiermit erkläre ich, dass ich die vorliegende Arbeit selbstständig
und ohne fremde Hilfe verfasst und keine anderen Hilfsmittel als
die angegebenen verwendet habe.

Insbesondere versichere ich, dass ich alle wörtlichen und
sinngemässen Übernahmen aus anderen Werken als solche kenntlich
gemacht habe.


_____________________________________________ (Ort, Datum)


_____________________________________________ (Unterschrift)
```